



Sistema de Monitoreo Inteligente con Streamlit + n8n + MCP

Arquitecturas de Producción y Cierre de Semestre

Prof. Lucas Miguel Iturriago Salas

Universidad Nacional de Colombia
Facultad de Ingeniería

Junio de 2026



1. Paradigma de Arquitecturas Desacopladas

2. Inferencia Determinista y Procesamiento Multimodal

En sistemas de IA de grado de producción, la separación de responsabilidades es crítica:

- **Capa de Presentación (Streamlit):** Actúa como un *Thin Client* (Cliente Delgado). Su única función es la captura de inputs y el renderizado reactivo de resultados.
- **Capa de Orquestación (n8n):** Centraliza la lógica de negocio, la gestión de secretos y el flujo de control de los agentes.

Ventajas de Ingeniería

- 1 **Seguridad:** Las API Keys y credenciales de base de datos nunca viajan al lado del cliente.
- 2 **Escalabilidad:** El motor de inferencia y la orquestación pueden escalar en infraestructura dedicada independientemente de la UI.


Model Context Protocol (MCP): Arquitectura Cliente-Servidor

El **MCP** es un estándar abierto para el intercambio de contexto entre Inteligencia Artificial y fuentes de datos.

División Estructural de Responsabilidades

- **MCP Server (Proveedor de Contexto):** Un proceso o servicio independiente expuesto local o remotamente (APIs, Filesystems, DBs). Abstrae la complejidad de la fuente original y expone recursos bajo un protocolo unificado.
- **MCP Client (El Orquestador / Host):** En nuestro caso, **n8n**. Es el entorno que gobierna la sesión, mantiene el estado de la aplicación, interactúa directamente con el LLM y traduce las intenciones del modelo en llamadas reales hacia el servidor.
- **LLM / AI Agent (El Motor Cognitivo):** No se conecta directamente al servidor. El cliente le presenta las capacidades del servidor en lenguaje natural para que el modelo decida el flujo lógico.

Model Context Protocol (MCP): Arquitectura Cliente-Servidor



Un **MCP Server** expone sus capacidades al **MCP Client** a través de tres contratos semánticos estrictos que el LLM puede interpretar de forma nativa:

1 Prompts (Plantillas de Entrada):

- *Qué son:* Atajos conversacionales o flujos de prompts preconfigurados en el servidor.
- *Para qué sirven:* Simplifican la interacción del usuario final al estandarizar cómo el agente debe abordar ciertas tareas o roles complejos.

2 Resources (Datos Estáticos/Pasivos):

- *Qué son:* Fuentes de datos de solo lectura que se pueden identificar unívocamente mediante URLs (ej. `file://logs/error.txt` o `postgres://tabla/datos`).
- *Para qué sirven:* Permiten al cliente inyectar contexto crudo directamente dentro de la ventana del modelo de forma estructurada.

3 Tools (Funcionalidad Activa/Ejecutable):

- *Qué son:* Funciones ejecutables con efectos secundarios en el entorno (*Function Calling*) que admiten argumentos validados por esquemas JSON.
- *Para qué sirven:* Dotan al agente de **agencia cibernética**, permitiéndole escribir en bases de datos (nuestro caso con Google Sheets) o disparar eventos físicos.

Para procesos de extracción de datos estructurados (PDF $\rightarrow$ DB), la estocasticidad es un riesgo de MLOps. Configuramos $T = 0,0$.

- La probabilidad de un token w_i se rige por la función *Softmax* con temperatura T :

$$P(w_i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

- Cuando $T \rightarrow 0$, el modelo realiza una decodificación **Greedy (Codiciosa)**:

$$P(w_t | w_{<t}) = \begin{cases} 1, & \text{si } w_t = \arg \max \text{ logits}(w) \\ 0, & \text{otros} \end{cases}$$

- **Resultado:** El agente se vuelve determinista, asegurando mapeos de herramientas consistentes y esquemas JSON válidos.

En arquitecturas orientadas a eventos (Webhooks), el transporte de archivos binarios requiere serialización:

- **Base64 Encoding:** Transforma bytes en texto ASCII para su transmisión segura en payloads JSON.
- **Contexto Masivo:** Aprovechamos la ventana de $\approx 10^6$ tokens de Gemini para procesar el reporte completo sin fragmentación (evitando RAG innecesario para documentos únicos).

Eficiencia Multimodal

El modelo no realiza OCR tradicional; procesa los tensores de imagen/documento nativamente, manteniendo la relación espacial de las métricas en el reporte técnico.